ML – 問題總整理 111652015 曹晉嘉

1. 為什麼只用少量的神經元，就可以有那麼好的近似能力 ？

相關研究就是「普適近似定理」與「近似誤差界」:
在適當的激活函數下，單隱藏層前饋神經網路就已經可以逼近任意連續函數，再加上一些「函數正則性」的假設，就可以證明只要適量的神經元就能得到足夠好的誤差上界。

文獻：

文獻：

- Hornik, Stinchcombe, White, Multilayer feedforward networks are universal approximators, Neural Networks, 1989.
    - 說明：證明單隱藏層前饋網路在很寬的一類激活函數下是普適近似器。
    - 連結：https://www.sciencedirect.com/science/article/pii/0893608089900208
- Cybenko, Approximation by superpositions of a sigmoidal function, MCS, 1989.
    - 說明 ： 只有一層隱藏層、啟動函數是 sigmoidal 的前饋神經網路，就已經可以逼近任何連續函數
    - 連結 ：https://web.njit.edu/~usman/courses/cs675_fall18/10.1.1.441.7873.pdf
- Approximation properties of a multilayered feedforward artificial neural network, Adv. Comput. Math., 1993
    - 連結 ：https://link.springer.com/article/10.1007/BF02070821

---

2. 我們能不能估計「需要多少個神經元」才能達到某種近似精度 ？

相關研究是「近似率／誤差率」:
對某些特定的函數類別，可以證明「要做到誤差 $\leq \varepsilon$ ，大約需要幾個神經元」。但這個數量會依賴：維度、函數的平滑度、網路是深還是淺等等條件。

文獻：

- Barron, Universal approximation bounds for superpositions of a sigmoidal function, IEEE Trans. Information Theory, 1993.

    - 說明：對所謂「Barron 函數」，給出用單隱藏層網路逼近時的誤差上界，誤差大約和「1/神經元數量」成比例，因此可以反推需要多少神經元。
    - 連結：http://www.stat.yale.edu/~arb4/publications_files/UniversalApproximationBoundsForSuperpositionsOfASigmoidalFunction.pdf

- Barron, Approximation and estimation bounds for artificial neural networks, Machine Learning, 1994.
    - 說明：同時討論「近似誤差 + 統計估計誤差」。
    - 連結：https://link.springer.com/article/10.1007/BF00993164
- Yarotsky, Error bounds for approximations with deep ReLU networks, Neural Networks, 2017.
    - 說明：對 ReLU 深度網路，在 Sobolev 空間裡建立了深度、寬度（神經元數）、近似誤差之間的定量關係，可用來估計需要多大的網路。
    - 連結：https://arxiv.org/abs/1610.01145

---

3. 用神經網路近似一個函數時，近似誤差是不是跟神經元數量成反比 ？

相關研究：

- 對特定函數類（例如 Barron 類），誤差可以達到 ≈ C / N（N 是神經元數）這種一階收斂率。
- 一般情況下，誤差和 N 的關係可能是 N^(-α)、或帶 log 因子，而且還會跟維度、平滑度、深度有關，不是一律「1/N」。

文獻：

- Barron, Universal approximation bounds for superpositions of a sigmoidal function, 1993.
    - 說明：對某個函數類別，給出像是 O(1/N) 的誤差界，這是「誤

差與神經元數目關係」的一個經典範例。

    - 連結：http://www.stat.yale.edu/~arb4/publications_files/UniversalApproximationBoundsForSuperpositionsOfASigmoidalFunction.pdf

- Yarotsky, Error bounds for approximations with deep ReLU networks, 2017.
    - 說明：對 ReLU，展示不同深度下誤差隨著「總參數數量、層數」如何縮減，顯示深度可以改善誤差率，不一定只是單純的 1/N。
    - 連結：https://arxiv.org/pdf/1610.01145
- Siegel & Xu, Approximation rates for shallow neural networks
    - 說明：給出淺層網路的下界與上界，說明在很多情況下，誤差無法比某種 N^(-α) 更好，因此「誤差 $\propto$ 1/N」只是特定條件下的特例。
    - 連結：https://arxiv.org/pdf/2408.10996

---

4. 訓練資料的筆數，以及訓練的 epoch 次數，會怎麼影響訓練效果 ？

想關研究：

- 資料量：在標準統計學習理論中，一般會得到
    - 測試誤差 $\lesssim$ 近似誤差 + O(√(模型複雜度 / 資料量))，
    - 所以資料越多，估計誤差通常以 1/√n 的速度下降。
- 訓練 epochs：
    - 增加 epochs 通常會讓訓練誤差下降；
    - 但測試誤差會先降再可能上升（overfitting），只是在深度學習中，「隱含正則化」讓這個行為變得很複雜。

文獻（有對應研究）：

- Shalev-Shwartz & Ben-David, Understanding Machine Learning: From Theory to Algorithms, 2014.

    - 說明：整理「樣本數 n、模型複雜度、上界型誤差」之間的關係。
    - 連結：https://www.cs.huji.ac.il/~shais/UnderstandingMachineLearning/understanding-machine-learning-theory-algorithms.pdf

- Barron, Approximation and estimation bounds for artificial neural networks, 1994.
    - 說明：把「近似誤差 + 統計估計誤差」分開處理，顯示樣本數如何控制估計誤差。
    - 連結 ：https://link.springer.com/article/10.1007/BF00993164
- Neyshabur et al., Exploring generalization in deep learning, NeurIPS 2017.
    - 說明：討論不同「容量測度」（權重范數、margin 等）如何影響泛化程度，也與訓練時長與正則化有關。
    - 連結：https://arxiv.org/pdf/1706.08947
- Zhang et al., Understanding deep learning requires rethinking generalization, ICLR 2017.
    - 說明：展示深度網路可以把訓練資料幾乎都背起來（訓練誤差 ≈ 0），但在很多情況下測試誤差仍然很好，說明「epochs 數量 vs 泛化」並非簡單線性關係。
    - 連結：https://arxiv.org/pdf/1611.03530

---

5. 有沒有一個「公式」可以把：資料量、重複次數、以及其他參數，和訓練後模型對目標的誤差關係寫在一起 ？

結論：

- 目前沒有一條「簡單、適用所有神經網路」的閉式公式，可以直接帶「資料量、迭代次數、learning rate、網路深度」就算出最終誤差。
- 但有很多上界形式的「學習曲線」與「誤差界」，大致形如
    - 測試誤差 ≤ 近似誤差（ 網路大小 ） + 統計誤差（ 樣本數與容

量)　+ 最佳化誤差（ 訓練不完全 ）。

文獻：

- Barron, Approximation and estimation bounds for artificial neural networks, 1994.
    - 說明：提供「總誤差 = approximation + estimation」的框架，可看成一種「誤差公式」，只是沒有把 epochs 寫進去。
    - 連結 ：https://link.springer.com/article/10.1007/BF00993164
- Shalev-Shwartz & Ben-David, Understanding Machine Learning, 2014.
    - 說明：給出很多 generalization bound，一般形式是「測試誤差 ≤ 訓練誤差 + O(√(complexity/n))」。
    - 連結 ：https://www.cs.huji.ac.il/~shais/UnderstandingMachineLearning/understanding-machine-learning-theory-algorithms.pdf
- Su & Yang, A Survey on the Theoretical Foundations of Deep Learning, 2019/2020
    - 說明：整理各種深度學習的統計理論與誤差分析，強調目前並沒有一條簡單方程式能把所有超參數都寫進去。
    - 連結：https://link.springer.com/article/10.1007/s10462-025-11368-7

---

6. 要如何選擇合適的隱藏層數目與每層神經元數量 ？

目前是經驗法則 + 理論建議 + 自動搜尋方法，但沒有單一最佳答案。
實務上會：

- 先用較簡單的架構（1－2 隱藏層、適中寬度）
- 用驗證集或交叉驗證來調整寬度、深度
- 或是使用自動化架構搜尋

文獻：

- Sheela & Deepa, Review on Methods to Fix Number of Hidden Neurons in Neural

Networks, Mathematical Problems in Engineering, 2013.

    - 說明：回顧各種決定「隱藏層神經元數」的方法，包括經驗公式、試誤與交叉驗證等。
    - 連結：https://onlinelibrary.wiley.com/doi/10.1155/2013/425740

- Huang, Learning capability and storage capacity of two-hidden-layer feedforward networks, IEEE Trans. Neural Networks, 2003
    - 說明：從理論角度分析兩層隱藏層網路的容量與表示能力，說明增加層數與寬度的影響。
    - 連結：https://ieeexplore.ieee.org/document/1189626
- Elsken et al., Neural Architecture Search: A Survey, JMLR, 2019.
    - 說明：整理自動化搜尋網路架構（包括層數、寬度等）的方法，是「自動選隱藏層與神經元」的一大類研究。
    - 連結：https://arxiv.org/pdf/1808.05377

---

7. 課堂上有提到啟動函數用 $\sigma(x) = 1 / (1 + e^{-x})$的原因, 那若用其他函數做為啟動函數會有什麼影 ?

相關研究：

- 多數常用激活函數（sigmoid, tanh, ReLU, leaky ReLU, ELU, Swish…）在理論上都能保證普適近似性（只要非多項式、適當條件）。
- 但在實務上會影響：
    - 梯度消失或爆炸（如 sigmoid 容易梯度消失，ReLU 在深網路較穩定）；
    - 訓練速度與穩定性；
    - 表示的稀疏性、非線性特徵的型態。

文獻：

- Dubey et al., Activation Functions in Deep Learning: A Comprehensive Survey

and Benchmark, 2022.

    - 說明：系統比較多種傳統與新型激活函數（ReLU、Swish、Mish 等），分析對訓練與性能的影響。
    - 連結：https://arxiv.org/pdf/2109.14545

- Apicella et al., A Survey on Modern Trainable Activation Functions, Neural Networks, 2021.
    - 說明：介紹可學習型啟動函數（如 PReLU、AParametric ReLU 等），也介紹如何改善表示能力與訓練。
    - 連結：https://arxiv.org/pdf/2005.00817

---

8. 我們假設的「類別條件高斯分佈」和真實資料分佈其實可能差很多，那 QDA 對這種 model misspecification 有多敏感 ？

- QDA 假設「每一類是高斯分布，且共變異數矩陣可以不同」。
- 若實際分布不是高斯：
    - 輕微偏離時，QDA 通常仍有不錯表現；
    - 嚴重偏離或樣本數太少時，估出來的共變異數可能不穩定，導致判別邊界非常不準，甚至數值上不穩。
- 因此有一系列「robust QDA / sparse QDA」研究，專門處理共變異數估計的誤差與模型誤設（model misspecification）。

文獻：

- Adebanji et al., Robustness of the Quadratic Discriminant Function to correlated and uncorrelated normal training samples, SpringerPlus, 2016.
    - 說明：研究在不同共變異數結構和樣本條件下，QDA 的穩健性與分類性能。
    - 連結：https://link.springer.com/article/10.1186/s40064-016-1718-3
- Sun et al., Application of sparse estimation of covariance matrix to quadratic discriminant analysis, BMC Bioinformatics, 2015.

    - 說明：提出 Sparse QDA，在高維、共變異數估計困難時仍能有較穩定的表現，因而減少模型誤判。
    - 連結：https://link.springer.com/article/10.1186/s12859-014-0443-6
- Kunjunni & Abraham, Robust quadratic discriminant analysis using Sn covariance, Communications in Statistics, 2021.
    - 說明：使用 robust covariance 估計法提升 QDA 面對非高斯與離群點時的穩定度。
    - 連結：https://www.tandfonline.com/doi/full/10.1080/03610918.2020.1868512#d1e144

---

9. 經緯度資料在做距離相關的學習時，是否需要做投影或縮放才能避免距離的變形 ？

- 地球是橢球，不是平面，所以「直接用緯度/經度做歐式距離」在大尺度會有明顯失真。
- 常見做法：
    - 只算兩點距離時，用 Haversine formula 計算大圓距離。
    - 若要把座標當成平面上的向量，用地圖投影（如 UTM）轉成「以公尺為單位的 (x,y) 坐標」，失真在某一區域內會被控制在很小。
    - 在 ML 裡，如果範圍不大，有時直接用經緯度搭配 tree-based 模型也還可以，但很多實務 paper 會先做投影或特徵工程。

文獻：

- Yin et al., GPS2Vec: Pre-trained Semantic Embeddings for Worldwide GPS Coordinates, IEEE TMM, 2021.
    - 說明：把經緯度轉成 UTM 等平面座標，再做向量化，展示投影後做 ML 的效果。
    - 連結：https://yifangyin.github.io/publications/TMM-21.pdf

10. 在隨機微分方程（SDE）裡，什麼是「強解」與「弱解」的差別 ？

- 強解：
    - Brownian motion（或 more generally，噪音）事先固定好，
    - 解是定義在這個固定的機率空間上、對應於這個 Brownian，
- 弱解：
    - 只要求「存在某個機率空間和某個 Brownian，使得這個 SDE 的分布條件被滿足」，
    - 也就是說，我們只在意「解的機率分布」，不強求在指定的 Brownian 上構造；

文獻：

- Øksendal, Stochastic Differential Equations: An Introduction with Applications, Springer (Universitext).
    - 說明：非常經典的 SDE 入門，第二、三章就定義了 strong/weak solution，並討論 Yamada–Watanabe 定理（強、弱解之間的關係）。
    - 連結：https://link.springer.com/book/10.1007/978-3-642-14394-6
- Ikeda & Watanabe, Stochastic Differential Equations and Diffusion Processes, North-Holland, 1989.
    - 說明：更進階的理論書，詳細討論強解、弱解、martingale problem 和 Markov 性質。
    - 連結 (須付費)：https://onlinelibrary.wiley.com/doi/epdf/10.1002/bimj.4710320720
- Ondreját, A note on weak solutions to stochastic differential equations, Kybernetika, 2018.
    - 說明：專門討論弱解存在性的技術證明。
    - 連結：https://www.kybernetika.cz/content/2018/5/888/paper.pdf

11. 給定一個 SDE，這個 SDE 是否存在解析的解 ？

結論：

- 只有少數簡單形式的 SDE 有 closed-form 解（例如幾何布朗運動、Ornstein – Uhlenbeck 過程，某些線性 SDE 等）。
- 絕大多數實務上的 SDE 沒有解析解，只能用數值方法（Euler – Maruyama、Milstein、Runge – Kutta 型 SDE 方法）近似。

文獻：

- Øksendal, Stochastic Differential Equations
    - 說明：介紹一些「有解析解」的典型 SDE（GBM、OU 等），並指出一般情況須用數值或近似。
    - 連結 ：https://link.springer.com/book/10.1007/978-3-642-14394-6
- Särkkä & Solin, Applied Stochastic Differential Equations, Cambridge University Press, 2019.
    - 說明：從應用角度整理 SDE 的解析解（能寫出來的那些）與數值近似方法，在濾波、軌跡追蹤等應用中很常用。
    - 連結 ：https://users.aalto.fi/~asolin/sde-book/sde-book.pdf
- Kloeden & Platen, Numerical Solution of Stochastic Differential Equations, Springer, 1992.
    - 說明：SDE 數值解專書，基本立場就是「多數 SDE 沒解析解，所以需要系統的數值方法」。
    - 連結：https://link.springer.com/book/10.1007/978-3-662-12616-5