ML – HW11 (問題二) 曹晉嘉 111652015

我設想中未來的 AI

- 給定疾病或治療需求，AI 能自動產生並篩選小分子藥物，並兼顧：
    - 對目標有足夠療效 (有效性高)
    - 毒性與副作用可接受 (毒性低)
    - 合成難度與成本合理 (可合成性高)
- 最終輸出一小批最值得投入實驗資源的候選分子

簡化模型定義

- 在一個有限的「候選分子集合」中，給定一個「治療需求」，訓練模型選出同時「有效性高、毒性低、可合成性高」的前 K 名分子

訓練階段的輸入與輸出

- 輸入：
    - 分子指紋向量：長度 256 的 0/1 向量，代表假想分子的結構特徵
    - 治療任務編號：整數 ID
- 輸出標籤：
    - 有效性、毒性、可合成性三個連續數值。

資料來源與生成方式

- 目前沒有真實實驗數據，因此在程式中使用「隱藏真實函數」自造資料：
    - 對每個治療任務編號設定一組隱藏權重，對分子指紋向量做線性組合加上噪音
    - 計算得到有效性、毒性、可合成性，並做標準化，作為模型要學習的資料

模型與訓練方法

- 模型：多輸出的全連接神經網路，輸入為「分子指紋向量」與治「療任務編號」串接向量，輸出三個預測值（ 有效性、毒性、可合成性 ）
- 訓練：
    - 將資料切成訓練集與測試集
    - 使用三個輸出平方誤差的總和作為損失函數
    - 在測試集上檢查三個性質的均方根誤差，確認模型能近似隱藏真實函數

使用階段的輸入與輸出

- 使用時先定義一個需求結構：
    - 一個集合包含目標靶點 target_id，有效性、毒性、可合成性的權重，以及硬門檻（ 有效性、毒性、可合成性的最低要求，避免搞出劇毒的藥物 ）
- 再給定一批候選分子指紋向量（ 在簡易模型中是用亂數生成的 ），模型對每個候選分子預測有效性、毒性、可合成性，並計算加上其權重的分數
- 濾掉不符合硬門檻的分子，依照分數排序，輸出前 K 名
- 因此使用階段的輸入是「需求結構 ＋ 候選分子集合」，輸出則是「通過門檻的前 k 名候選分子及其三個預測性質與總分」

評估與成功判準

- 在簡易模型中可以用隱藏真實分數評估：
    - 比較模型選出前 k 名與隨機選擇的前 k 名，在真實分數上的平均表現
    - 若模型的前 k 名真實分數明顯高於隨機，且接近「用真實分數排序得到的理想前 k 名排名」，則視為成功